PROJET BIG DATA · SMART CITY

UrbanHub

Concevoir un jumeau numérique urbain : collecter, stocker, analyser et exploiter les données d'une ville moderne.

PARTIE 1 · BATCH

Météo

NOAA Global Hourly

PARTIE 2 · STREAMING

Mobilité

CityBikes API

PARTIE 3 · IOT

Pollution

OpenAQ API

PARTIE 4

Analyse croisée

Météo × Mobilité × Air

SUJET DE PROJET

Contexte

Une **Smart City** génère en permanence des données provenant de multiples sources :

- ▸ Capteurs `IoT`
- ▸ Pollution, bruit, incidents
- ▸ Consommation énergétique
- ▸ Données environnementales et météorologiques
- ▸ Flux de trafic : *routier*, *ferroviaire*, *mobilité douce*...
- ▸ Événements urbains...

Ces données doivent être **collectées, stockées, analysées et exploitées** afin de produire des indicateurs utiles aux décideurs publics.

L'objectif du projet est de développer **la plateforme UrbanHub**, capable d'ingérer et d'analyser ces données. UrbanHub est ce qu'on appelle un **jumeau numérique urbain** : il permet d'observer et d'analyser le fonctionnement d'une ville moderne.

ARCHITECTURE CIBLE

La plateforme s'appuie sur les **trois types de flux typiques d'un système Big Data réel** :

FLUX 1	FLUX 2	FLUX 3
Batch	**Streaming**	**IoT**
Données historiques massives	Données temps réel	Données capteurs

Les données doivent être intégrées dans une architecture proche d'une plateforme Smart City :



FLUX BATCH

1 Analyse météorologique urbaine

SOURCE DE DONNÉES

NOAA Global Hourly Weather Data

`Index of /data/global-hourly/access/ — https://www.ncei.noaa.gov/data/global-hourly/access/`

Observations météorologiques horaires de stations météo situées dans le monde entier.

TRAVAIL DEMANDÉ

- Écrire un `script` qui télécharge **en parallèle** les fichiers correspondant aux stations météorologiques situées en France. **Pas de téléchargement des fichiers un par un**
- **Dimension temporelle :** les 5 dernières années

  Variables à extraire :

  `station_id` `timestamp` `temperature` `wind_speed` `wind_direction` `visibility` `pressure` `precipitation`
- Mettre en place les nettoyages possibles sur les données : *valeurs manquantes*, *conversion des unités*, du *timestamp*, etc.

QUESTIONS MÉTIER

Q1 Peut-on identifier des **périodes météorologiques anormales** ?

Q2 Existe-t-il une corrélation entre **conditions météorologiques et visibilité** ?

Q3 Quelle est l'évolution **saisonnière de la température** en France et dans les principales villes ?

Q4 Quels sont les **jours présentant des conditions météorologiques extrêmes** ?

FLUX STREAMING

2 Mobilité urbaine

SOURCE DE DONNÉES

CityBikes API

`Documentation | CityBikes API — https://api.citybik.es/v2/`

Informations en temps réel sur les stations de vélos en libre-service dans le monde.

TRAVAIL DEMANDÉ

- Mettre en place un système de récupération **automatique toutes les 2 à 3 minutes** des données de stations des principales villes de France.
- Extraire les variables suivantes pour chaque station (depuis l'existence du réseau Vélib') :

`station_id` `station_name` `timestamp` `latitude` `longitude` `free_slots` `bikes_available`

QUESTIONS MÉTIER

Q1 Quelles stations présentent **le plus fort taux d'utilisation** ?

Q2 Peut-on identifier des **zones où l'offre de vélos est insuffisante** ?

Q3 Quels sont les **pics d'utilisation journaliers** du réseau de vélos ?

Q4 Existe-t-il des **déséquilibres géographiques dans la disponibilité des vélos** ?

Q5 Peut-on détecter des **stations critiques nécessitant un rééquilibrage des vélos** ?

FLUX IOT

3 Pollution urbaine

SOURCE DE DONNÉES

OpenAQ REST API

`Pollution atmosphérique — https://docs.openaq.org/`

Données issues de capteurs de pollution installés dans plusieurs villes du monde.

TRAVAIL DEMANDÉ

- Collecter les données de la France, notamment des principales villes.
- Mettre en place une **ingestion régulière simulant un flux IoT**. Variables à extraire :

  `sensor_id` `pollutant` `timestamp` `latitude` `longitude` `value` `unit`

- Polluants principaux :

  PM2.5 **PM10** **NO_2** **O_3** **CO**

QUESTIONS MÉTIER

Q1 Quelles zones présentent les **niveaux de pollution les plus élevés** ?

Q2 Existe-t-il une **variation journalière de la pollution** ?

Q3 Quels polluants sont **les plus dominants dans la ville étudiée** ?

Q4 Peut-on identifier des **épisodes de pollution anormale** ?

BATCH × STREAMING × IOT

4 Analyse croisée des données

Les différentes sources doivent être **croisées** afin de produire des analyses urbaines.

QUESTIONS MÉTIER

Q1 Existe-t-il une relation entre **conditions météorologiques et pollution** ?

Q2 Les **conditions météo influencent-elles l'utilisation des vélos urbains** ?

Q3 Peut-on identifier des **conditions météorologiques favorables à la mobilité douce** ?

Q4 Existe-t-il des périodes où **mobilité, pollution et météo interagissent fortement** ?

À RENDRE

✓ Livrables attendus

01 Scripts de collecte des données

02 Stockage structuré des données

03 Pipeline de traitement

04 Analyses exploratoires

05 Visualisations

06 Interprétation des résultats

07 Vidéos de démonstration

`Démo-UrbanHub-Partie1.mp4 · Démo-UrbanHub-Partie2.mp4`